



PEMROSESAN BAHASA ALAMI

PERTEMUAN 3

MODEL BAHASA N-GRAM

PENGAMPU

WAYAN OGER VIHIKAN, S.T.I., M.I.T.

AGENDA

- Definisi Model Bahasa
- Model Bahasa N-gram
- Smoothing
- Men-*generate* Kalimat dari Model Bahasa
- Evaluasi Model Bahasa

DEFINISI MODEL BAHASA

- Distribusi probabilitas pada rangkaian kata
- Bermanfaat dalam pengenalan suara, translasi, language generation, memperbaiki ejaan, dsb
- Jenis model bahasa: n-gram, berbasis neural network, berbasis recurrent neural network, berbasis transformers

MODEL BAHASA N-GRAM

- Menghitung probabilitas rentetan kata (word sequence) berdasarkan probabilitas dari bagian rentetan kata (word subsequence)
 - Joint probability:
 - $p(\mathbf{w}) = p(w_1, w_2, w_3, \dots, w_m)$
 - Ubah ke conditional probability:
 - $p(\mathbf{w}) = p(w_1) * p(w_2 | w_1) * p(w_3 | w_1, w_2) * \dots * p(w_m | w_1, \dots, w_{m-1})$
 - $\mathbf{w}$ = word sequence
 - m = banyaknya kata
- Membuat aproksimasi: kondisi yang digunakan berasal dari kata $n-1$ terakhir
 - $p(w_m | w_1, \dots, w_{m-1}) \approx p(w_m | w_{m-n+1}, \dots, w_{m-1})$
 - Nilai n merupakan variabel, dapat bernilai 1, 2, 3, dst

MODEL BAHASA N-GRAM

- Unigram: $n = 1$
 - $P(w_1, w_2, \dots, w_m) = \prod_{i=1}^m P(w_i)$
- Bigram: $n = 2$
 - $P(w_1, w_2, \dots, w_m) = \prod_{i=1}^m P(w_i | w_{i-1})$
- Trigram: $n = 3$
 - $P(w_1, w_2, \dots, w_m) = \prod_{i=1}^m P(w_i | w_{i-2}, w_{i-1})$
- Menghitung probabilitas:
 - $P(w_i | w_{i-n+1}, w_{i-1}) = \frac{C(w_{i-n+1} \dots w_i)}{C(w_{i-n+1} \dots w_{i-1})}$

CONTOH | MODEL BAHASA N-GRAM

- Corpus:
 - yes no no no no yes
 - no no no yes yes yes no
- Berapakah nilai probabilitas rentetan kata berikut dalam model trigram:
 - yes no no yes

CONTOH | MODEL BAHASA N-GRAM

- Corpus:
 - $\langle s \rangle \langle s \rangle$ yes no no no no yes $\langle /s \rangle$
 - $\langle s \rangle \langle s \rangle$ no no no yes yes yes no $\langle /s \rangle$
- Berapakah nilai probabilitas rentetan kata berikut dalam model trigram:
 - $\langle s \rangle \langle s \rangle$ yes no no yes $\langle /s \rangle$
 $w_1 \quad w_2 \quad w_3 \quad w_4 \quad w_5 \quad w_6 \quad w_7$
 - $\prod_{i=1}^m P(w_i | w_{i-2}, w_{i-1})$
 - $P(\text{yes} | \langle s \rangle \langle s \rangle) * P(\text{no} | \langle s \rangle \text{yes}) * P(\text{no} | \text{yes no}) * P(\text{yes} | \text{no no}) * P(\langle /s \rangle | \text{no yes})$
 - $\frac{1}{2} * 1 * \frac{1}{2} * \frac{2}{5} * \frac{1}{2} = 0.05$

MASALAH | MODEL BAHASA N-GRAM

- Efek antar komponen dari bahasa berjarak jauh
 - **Para peserta** yang mengikuti seminar sangat antusias karena bagi **mereka** banyak ilmu baru yang didapatkan
 - Penggunaan “mereka” dapat diketahui jika bisa melihat konteks “para peserta”
- Nilai probability biasanya sangat kecil
 - Dapat diatasi dengan log
- Tidak ada probabilitas untuk kata yang belum pernah terlihat
 - Gunakan simbol khusus untuk merepresentasikannya, misalnya <UNK>
- Kata pada konteks baru
 - Untuk n-gram yang belum pernah terlihat, nilainya akan 0, sehingga probabilitas dari kalimat tersebut adalah 0
 - Dapat diatasi dengan smoothing

SMOOTHING

- Gunakan suatu nilai probabilitas untuk n-gram yang belum pernah terlihat
- Ada beberapa jenis smoothing:
 - Laplace smoothing
 - Lidstone smoothing
 - Absolute discounting
 - Kneser-Ney smoothing

LAPLACE | SMOOTHING

- Asumsikan bahwa n-gram yang belum pernah terlihat terjadi 1 kali
- Gunakan variabel α
- Pada Laplace nilai α adalah 1
- Sehingga pada 2-gram:
 - $P(w_i|w_{i-1}) = \frac{C(w_{i-1},w_i)+\alpha}{C(w_{i-1})+|V|\times\alpha}$
 - $P(w_i|w_{i-1}) = \frac{C(w_{i-1},w_i)+1}{C(w_{i-1})+|V|\times 1}$
 - V adalah jumlah kosa kata

LIDSTONE | SMOOTHING

- Hampir sama seperti Laplace smoothing hanya saja nilai α diantara 0 sampai 1, misal 0.1
- Sehingga pada 2-gram:
 - $P(w_i|w_{i-1}) = \frac{C(w_{i-1},w_i)+0.1}{C(w_{i-1})+|V|\times 0.1}$
 - V adalah jumlah kosa kata

ABSOLUTE DISCOUNTING | SMOOTHING

- Mengambil nilai probabilitas dari n-gram yang muncul dan mendistribusikannya secara adil ke n-gram yang tidak pernah muncul
- Menggunakan variable d yang menunjukkan nilai discount,
- Sehingga:

- $$P(w_i|w_{i-1}) = \begin{cases} \frac{C(w_{i-1}, w_i) - d}{C(w_{i-1})}, & \text{if } C(w_{i-1}, w_i) > 0 \\ \frac{\alpha(w_{i-1})}{C(w_{i-1})} : N, & \text{otherwise} \end{cases}$$
- $\alpha(w_{i-1})$ merupakan jumlah nilai yang sudah didiskon dari konteks w_{i-1}
- N merupakan n-gram yang tidak pernah muncul

ABSOLUTE DISCOUNTING | SMOOTHING

$$P(? | \text{alleged}) =$$

			Lidstone smoothing, $\alpha = 0.1$	Discounting, $d = 0.1$
	counts	unsmoothed probability	smoothed probability	smoothed probability
<i>impropriety</i>	8	0.4	0.391	0.395
<i>offense</i>	5	0.25	0.246	0.245
<i>damage</i>	4	0.2	0.198	0.195
<i>deficiencies</i>	2	0.1	0.101	0.095
<i>outbreak</i>	1	0.05	0.053	0.045
<i>infirmity</i>	0	0	0.005	0.013
<i>cephalopods</i>	0	0	0.005	0.013

KNESER-NEY | SMOOTHING

- Mengambil nilai probabilitas dari n-gram yang muncul dan mendistribusikannya berdasarkan banyaknya kata w muncul pada konteks yang berbeda

- $$P(w_i | w_{i-1}) = \begin{cases} \frac{C(w_{i-1}, w_i) - d}{C(w_{i-1})}, & \text{if } C(w_{i-1}, w_i) > 0 \\ \alpha(w_{i-1}) P_{cont}(w_i), & \text{otherwise} \end{cases}$$

- $$P_{cont}(w_i) = \frac{|\{w_{i-1} : C(w_{i-1}, w_i) > 0\}|}{|\{(w_{j-1}, w_j) : C(w_{j-1}, w_j) > 0\}|}$$

Jumlah kata unik yang pernah muncul sebelum w_i


Jumlah seluruh bigram yang pernah muncul

MEN-GENERATE KALIMAT

- Berdasarkan kata-kata awal yang diberikan, munculkan kata berikutnya dengan menghitung distribusi probabilitas yang dimiliki oleh suatu model Bahasa
- Misalnya pada 2-gram, gunakan kata $n-1$ sebagai konteks awal untuk memunculkan kata berikutnya
 - Tambahkan rules seperti: jangan memunculkan $\langle s \rangle$
 - Munculkan $\langle /s \rangle$ sebagai berakhirnya suatu rentetan kata
- Kata selanjutnya merupakan kata dengan probabilitas tertinggi disaat itu (greedy)


CONTOH 2-GRAM | MEN-GENERATE KALIMAT

- Kalimat: <s>
- $P(? \mid <s>) = \text{Saya}$




CONTOH 2-GRAM | MEN-GENERATE KALIMAT

- Kalimat: <s> Saya
- $P(? \mid \text{Saya}) = \text{Makan}$




CONTOH 2-GRAM | MEN-GENERATE KALIMAT

- Kalimat: <s> Saya Makan
- $P(? \mid \text{Makan}) = \text{Nasi}$



CONTOH 2-GRAM | MEN-GENERATE KALIMAT

- Kalimat: <s> Saya Makan Nasi
- $P(? \mid \text{Nasi}) = \text{Goreng}$



CONTOH 2-GRAM | MEN-GENERATE KALIMAT

- Kalimat: <s> Saya Makan Nasi Goreng
- $P(? \mid \text{Goreng}) = \text{</s>}$



CONTOH 2-GRAM | MEN-GENERATE KALIMAT

- Kalimat: <s> Saya Makan Nasi Goreng </s>

EVALUASI MODEL BAHASA

- Menghitung nilai *perplexity* pada test set
 - Perplexity berarti “kebingungan”
 - Semakin besar nilai perplexity artinya model bahasa semakin bingung (tidak percaya diri)
 - Model Bahasa yang baik memiliki nilai perplexity yang kecil
- Perplexity:

- $$PP(w_1, w_2, \dots, w_m) = \sqrt[m]{\frac{1}{P(w_1, w_2, \dots, w_m)}}$$
- $$PP(w_1, w_2, \dots, w_m) = 2^{-\frac{\log_2 P(w_1, w_2, \dots, w_m)}{m}}$$

LATIHAN

- Corpus:
 - Para peserta yang mengikuti seminar sangat antusias karena bagi mereka banyak ilmu baru yang didapatkan
 - Peserta lomba komputer sangat senang karena mendapatkan banyak ilmu baru
- Probabilitas “peserta mendapatkan ilmu baru” dengan bigram?



PERTEMUAN BERIKUTNYA ...

Sequence Labelling