



PEMROSESAN BAHASA ALAMI

PERTEMUAN 2

PRA-PEMROSESAN TEKS

PENGAMPU

WAYAN OGER VIHIKAN, S.T.I., M.I.T.

AGENDA

- Definisi Preprocessing
- Segmentasi Kalimat
- Tokenisasi Kata
- Normalisasi Kata
- Menghapus Stopword

PRA-PEMROSESAN

- Aplikasi pemrosesan bahasa alami memiliki input dalam bentuk dokumen, misalnya twit, artikel berita, paragraph, dsb.
- Dokumen tersebut tersusun atas beberapa komponen seperti kalimat dan kata.
- Untuk dapat memahami dokumen, komputer perlu mengetahui komponen tersebut.
- Pra-pemrosesan merupakan langkah awal dalam aplikasi PBA
- Langkah-langkah umum dalam preprocessing: menghapus format yang tidak diperlukan (tag HTML) => segmentasi kalimat => tokenisasi kata => normalisasi kata => menghapus stop words.

SEGMENTASI KALIMAT

- Cara termudah: memisahkan berdasarkan tanda baca yaitu [.?!]
 - Tapi ada beberapa kata seperti Yahoo!, U.S., Mr. Brown, dsb
- Gunakan machine learning:
 - Cari setiap [.?!], kemudian tentukan apakah menyatakan akhir dari kalimat.
 - Bisa dirumuskan sebagai klasifikasi biner (akhir kalimat atau tidak).
 - Fitur (sebagai input):
 - Kata di posisi sebelum dan setelah [.?!]
 - Bentuk kata (huruf besar / kecil, angka, jumlah huruf)
 - Tag part of speech => determiner seperti the, a, umumnya memulai kalimat baru.

TOKENISASI KATA

- Cara termudah: memisahkan dengan regex (`\w+`)
- Namun ada banyak kekurangan:
 - Singkatan: U.S.A.
 - Kata dengan tanda hubung: well-respected, masing-masing
 - Angka: 1.000,00
 - Tanggal: 12/09/2022
 - Istilah dari internet: www.google.com, #throwbackthursday
 - Kata yang terdiri dari dua kata atau lebih: New Zealand

TOKENISASI SUB-KATA

- Salah satu algoritma tokenisasi sub-kata: Byte Pair Encoding (BPE).
 - Menggabungkan karakter yang sering muncul secara berulang.
 - Dapat berguna untuk beragam Bahasa.
 - Dapat mengatasi kata yang tidak diketahui.

BYTE PAIR ENCODING

- Corpus:
 - low low low low low lowest lowest newer newer newer newer newer newer wider wider wider new new
- Dictionary:
 - [5] low _
 - [2] lowest _
 - [6] newer _
 - [3] wider _
 - [2] new _
- Vocabulary:
 - _, d, e, i, l, n, o, r, s, t, w

BYTE PAIR ENCODING

- Corpus:
 - low low low low low lowest lowest newer newer newer newer newer newer wider wider wider new new
- Dictionary:
 - [5] low _
 - [2] lowest _
 - [6] new **er** _
 - [3] wid **er** _
 - [2] new _
- Vocabulary:
 - _, d, e, i, l, n, o, r, s, t, w, **er**

er muncul 9 kali

BYTE PAIR ENCODING

- Corpus:
 - low low low low low lowest lowest newer newer newer newer newer newer wider wider wider new new
- Dictionary:
 - [5] low _
 - [2] lowest _
 - [6] new **er_**
 - [3] wid **er_**
 - [2] new _
- Vocabulary:
 - _, d, e, i, l, n, o, r, s, t, w, er, **er_**,

er_ muncul 9 kali

BYTE PAIR ENCODING

- Corpus:
 - low low low low low lowest lowest newer newer newer newer newer newer wider wider wider new new
- Dictionary:
 - [5] l o w _
 - [2] l o w e s t _
 - [6] **ne** w e r _
 - [3] w i d e r _
 - [2] **ne** w _
- Vocabulary:
 - _, d, e, i, l, n, o, r, s, t, w, e r, e r_, **ne**

ne muncul 8 kali

BYTE PAIR ENCODING

- Corpus:
 - low low low low low lowest lowest newer newer newer newer newer newer wider wider wider new new
- Dictionary:
 - [5] l o w _
 - [2] l o w e s t _
 - [6] **new** e r _
 - [3] w i d e r _
 - [2] **new** _
- Vocabulary:
 - _, d, e, i, l, n, o, r, s, t, w, e r, e r_, n e, **new**

new muncul 8 kali

BYTE PAIR ENCODING

- Vocabulary:
 - _, d, e, i, l, n, o, r, s, t, w, er, er_, ne, new, **lo**
 - _, d, e, i, l, n, o, r, s, t, w, er, er_, ne, new, lo, **low**
 - _, d, e, i, l, n, o, r, s, t, w, er, er_, ne, new, lo, low, **newer_**
 - _, d, e, i, l, n, o, r, s, t, w, er, er_, ne, new, lo, low, newer_, **low_**

BYTE PAIR ENCODING

- Dictionary:
 - low_
 - lowest_
 - newer_
 - wider_
 - new_
- Final vocabulary setelah 8 kali penggabungan:
 - _, d, e, i, l, n, o, r, s, t, w, er, er_, ne, new, lo, low, newer_, low_

NORMALISASI KATA

- Tujuan:
 - Mengurangi jumlah kosa kata (vocabulary).
 - Memetakan kata ke bentuk yang sama.
- Mengubah ke huruf kecil: Universitas Udayana => universitas udayana
- Menghapus morfologi
- Memperbaiki ejaan
- Mengubah singkatan: U.S.A => USA, imho => in my humble opinion

LEMATISASI

- Menghapus *inflection* dan menjadikan kata dasar (lemma)
 - speaking => speak
 - stopping => stop
 - memakan => makan
- Kamus (lexicon) kata dasar diperlukan untuk melakukan lematisasi yang akurat.

STEMMING

- Menghapus *inflection* dan menyederhanakan kata turunan sehingga menjadi stem.
 - Menghapus sufiks.
 - Misal: automate, automatic, automation => automat
 - Stem belum tentu memiliki makna / tidak ada pada kamus.

PORTER STEMMER

- Stemmer yang paling sering digunakan untuk Bahasa Inggris.
- Dapat di representasikan dalam bentuk:
 - $[C](VC)^m[V]$
 - C: Consonant (huruf mati) sequence
 - V: Vowel (huruf hidup) sequence
 - m: measure (banyaknya perulangan), bukan pangkat
 - [C]: Huruf konsonan yang optional
 - [V]: Huruf vokal yang optional
- Misal:
 - TREE $\Rightarrow C(VC)^0V$
 - TREES $\Rightarrow C(VC)^1$

PORTER STEMMER

- Langkah 1: Kata majemuk dan Kata lampau (past participle)

Langkah	Rule	Contoh Sesuai	Contoh Tidak Sesuai
1a	SSES → SS	caresses → caress	
	IES → I	ponies → poni	
	SS → SS	caress → caress	
	S → null	cats → cat	
1b	(m>0) EED → EE	agreed → agree	feed → feed
	(*v*) ED → null *v* = stem contains vowel	plastered → plaster	bled → bled
	(*v*) ING →	motoring → motor	sing → sing
1b+	AT → ATE	conflat(ed) → conflate	
	...		
c	(*v) Y → I	happy → happi	

PORTER STEMMER

- Langkah 2,3,4: Infleksi pada kata turunan

Langkah	Rule	Contoh Sesuai
2	(m>0) ATIONAL → ATE	relational → relate
	(m>0) TIONAL → TION	conditional → condition
	(m>0) ENCI → ENCE	valenci → valence
	(m>0) ANCI → ANCE	hesitanci → hesitance
	...	
3	(m>0) ICATE → IC	triplicate → triplic
	(m>0) ATIVE → null	formative → form
	(m>0) ALIZE → AL	formalize → formal
	...	
4	(m>1) AL → null	revival → reviv
	(m>1) ER → null	airliner → airlin
	(m>1) ATE → null	activate → activ
	...	

PORTER STEMMER

- Langkah 5: Finalisasi

Langkah	Rule	Contoh Sesuai
5	(m>1) E → null	probate → probat
	(m=1 and not *o) E → null *o = stem ends CVC, and second C is not w, x or y (e.g. -WIL, -HOP)	cease → ceas
	(m>1 and *d and *L) null → single letter *d = stem ends with double consonant (e.g. -TT)	controll → control

PORTER STEMMER

- Contoh 1:
 - Computational
 - Langkah 2: ATIONAL => ATE: computate
 - Langkah 4: ATE => null: comput
- Contoh 2:
 - Computer
 - Langkah 4: ER => null: comput

MENGHAPUS STOP WORD

- Daftar kata yang akan dihapus pada suatu dokumen.
 - ✓ Kata-kata tersebut terlalu sering muncul pada suatu dokumen.
 - ✓ Umumnya digunakan pada representasi bag-of-words (BOW).
 - ✓ Kurang sesuai untuk representasi yang menggunakan *sequence*.
- Stop Words:
 - ✓ Bahasa Inggris: the, a, of, for, and, or
 - ✓ Bahasa Indonesia: yang, dan, atau, untuk

CONTOH IMPLEMENTASI

- Pra-pemrosesan Teks Bahasa Inggris
 - https://colab.research.google.com/drive/1k6BX_N1GI1P3Cud8DXG_ZqYjQVrfsISC#scrollTo=1xVb3OIR_Vgq
- Pra-pemrosesan Teks Bahasa Indonesia (Latihan)
 - https://colab.research.google.com/drive/1YMtOfRnoWXp0D5Y_qACkEGO8qO2B1MHH#scrollTo=11UbK1zENU_1



PERTEMUAN BERIKUTNYA ...

N-gram