



PEMROSESAN BAHASA ALAMI

PERTEMUAN 4

PART OF SPEECH TAGGING

PENGAMPU

WAYAN OGER VIHIKAN, S.T.I., M.I.T.

AGENDA

- Definisi Part of Speech Tagging
- Tagsets
- Tagger berdasarkan aturan
- Tagger berdasarkan statistik
 - Tagger Unigram
 - Tagger berdasarkan classifier
 - Tagger berdasarkan Hidden Markov Model

DEFINISI PART OF SPEECH (POS) TAGGING

- POS: suatu label yang menandakan kelas kata
 - Kata benda, kata kerja, kata sifat, dll
- POS Tagging: proses untuk memberikan label pada masing-masing kata dalam suatu kalimat
- Mengetahui POS suatu kata membantu mengetahui jenis kata disekitarnya:
 - **Noun** diawali oleh **determiner** => **The dog**
 - **Verb** diawali oleh **noun** => **The dog barks**
- Membantu proses NER pada ekstraksi informasi
 - Jakarta adalah ibu kota Indonesia => ibu_kota(Indonesia, Jakarta)

DEFINISI PART OF SPEECH (POS) TAGGING

- Beberapa kata memiliki beberapa kelas
- POS membantu mengurangi ambiguitas suatu kata:
 - “**Book** that flight” dan “Hand me that **book**”
 - “Time **flies** like an arrow” dan “Fruit **flies** like a banana”

TAG SET

- Kumpulan tag, umumnya ≤ 4 huruf, missal NN, NNS, NNPS
- Tagset yang paling umum digunakan adalah Penn Treebank (45 tags)
 - NN: noun, VB: verb, JJ: adjective, RB: adverb, DT: determiner, dll
- Tag umumnya ditulis diakhir kata yang dipisahkan dengan "/"
 - The dog barks $\Rightarrow$ The/DT dog/NN bark/VB

PENN TREEBANK | TAG SET

Tag	Description	Example	Tag	Description	Example	Tag	Description	Example
CC	coordinating conjunction	<i>and, but, or</i>	PDT	predeterminer	<i>all, both</i>	VBP	verb non-3sg present	<i>eat</i>
CD	cardinal number	<i>one, two</i>	POS	possessive ending	<i>'s</i>	VBZ	verb 3sg pres	<i>eats</i>
DT	determiner	<i>a, the</i>	PRP	personal pronoun	<i>I, you, he</i>	WDT	wh-determ.	<i>which, that</i>
EX	existential 'there'	<i>there</i>	PRP\$	possess. pronoun	<i>your, one's</i>	WP	wh-pronoun	<i>what, who</i>
FW	foreign word	<i>mea culpa</i>	RB	adverb	<i>quickly</i>	WP\$	wh-possess.	<i>whose</i>
IN	preposition/ subordin-conj	<i>of, in, by</i>	RBR	comparative adverb	<i>faster</i>	WRB	wh-adverb	<i>how, where</i>
JJ	adjective	<i>yellow</i>	RBS	superlatv. adverb	<i>fastest</i>	\$	dollar sign	<i>\$</i>
JJR	comparative adj	<i>bigger</i>	RP	particle	<i>up, off</i>	#	pound sign	<i>#</i>
JJS	superlative adj	<i>wildest</i>	SYM	symbol	<i>+, %, &</i>	“	left quote	<i>‘ or “</i>
LS	list item marker	<i>1, 2, One</i>	TO	“to”	<i>to</i>	”	right quote	<i>’ or ”</i>
MD	modal	<i>can, should</i>	UH	interjection	<i>ah, oops</i>	(	left paren	<i>[, (, {, <</i>
NN	sing or mass noun	<i>llama</i>	VB	verb base form	<i>eat</i>	)	right paren	<i>],), }, ></i>
NNS	noun, plural	<i>llamas</i>	VBD	verb past tense	<i>ate</i>	,	comma	<i>,</i>
NNP	proper noun, sing.	<i>IBM</i>	VBG	verb gerund	<i>eating</i>	.	sent-end punc	<i>. ! ?</i>
NNPS	proper noun, plu.	<i>Carolinas</i>	VBN	verb past part.	<i>eaten</i>	:	sent-mid punc	<i>: ; ... - -</i>

RULE-BASED | TAGGING OTOMATIS

- Digunakan sebelum era machine learning
- Mengumpulkan daftar tag yang mungkin untuk masing-masing kata pada kamus
- Pahami aturan-aturan tata bahasa, kemudian aplikasikan aturan tersebut hingga mendapatkan suatu tag
 - Jika suatu kata memiliki tag DT maka untuk kata berikutnya tidak mungkin VB
- Rule-based tagging terlalu kompleks karena memiliki banyak sekali aturan-aturan
- Susah beradaptasi pada kata baru

UNIGRAM-BASED | TAGGING OTOMATIS

- Melakukan tagging berdasarkan statistik
- Harus menyiapkan training data berupa corpus yang sudah di tag
- Model hasil training hanya berupa tabel pencarian
- Ketika ada suatu kalimat baru:
 - Tokenize kalimat menjadi token
 - Untuk setiap token, cari tag yang memungkinkan pada model, kemudian hitung jumlah kejadian masing-masing tag
 - Tag yang dipilih adalah tag yang paling sering terjadi
- Akurasi dari metode ini umumnya cukup baik ~90%
- Biasanya digunakan sebagai baseline untuk metode-metode yang lebih kompleks

CLASSIFIER-BASED | TAGGING OTOMATIS

- Menggunakan algoritma machine learning (logistic regression, neural network) untuk menentukan tag
- Fitur yang dapat digunakan:
 - Kata yang akan dicari tagnya
 - Kata sebelum dan sesudahnya
 - Tag pada kata sebelumnya
- Performa lebih baik dari unigram tagger, namun memiliki masalah error propagation
 - Prediksi yang salah pada langkah sebelumnya dapat memberikan prediksi yang salah pada langkah berikutnya

HIDDEN MARKOV MODEL | TAGGING OTOMATIS

- Model sekuensial yang memberikan tag pada tiap token secara berurutan
- Seperti classifier-based yang memerlukan tag dan token sebelumnya, tapi memperlakukan tag dan token tersebut secara independen
- Memperhatikan probabilitas
 - Menghitung probabilitas urutan tag yang memungkinkan, kemudian pilih urutan tag terbaik
- Algoritma yang cepat untuk melakukan prediksi sekuensial

RUMUS HMM | TAGGING OTOMATIS

- Tujuan: Mendapatkan urutan tag terbaik $\mathbf{t}$ dari kalimat $\mathbf{w}$
 - $\hat{t} = \operatorname{argmax}_t P(\mathbf{t}|\mathbf{w})$
 - $\hat{t} = \operatorname{argmax}_t \frac{P(\mathbf{w}|\mathbf{t})P(\mathbf{t})}{P(\mathbf{w})} \Rightarrow$ Denominator $P(\mathbf{w})$ dapat dihilangkan karena melakukan argmax, sehingga:
 - $\hat{t} = \operatorname{argmax}_t P(\mathbf{w}|\mathbf{t})P(\mathbf{t})$
- Dijabarkan:
 - $P(\mathbf{w}|\mathbf{t}) = \prod_{i=1}^n P(w_i|t_i)$
 - $P(\mathbf{t}) = \prod_{i=1}^n P(t_i|t_{i-1})$
- Hidden karena urutan tag yang optimal tidak bisa kita lihat
- Markov karena menggunakan asumsi Markov chain $\Rightarrow$ probabilitas suatu even (tag) bergantung pada even sebelumnya (tag sebelumnya)

MELATIH HMM | TAGGING OTOMATIS

- $P(w_i|t_i) \Rightarrow$ probabilitas emisi
- $P(t_i|t_{i-1}) \Rightarrow$ probabilitas transisi
- Proses training dilakukan dengan cara menghitung frekuensi kata berdasarkan tagnya
- $P(\textit{like}|\textit{VB}) = \frac{\textit{count}(\textit{VB}, \textit{like})}{\textit{count}(\textit{VB})}$
- $P(\textit{NN}|\textit{VB}) = \frac{\textit{count}(\textit{VB}, \textit{NN})}{\textit{count}(\textit{VB})}$
- Gunakan simbol $\langle s \rangle$ dan $\langle /s \rangle$ untuk menandakan awal dan akhir kalimat
- $P(\textit{NN} | \langle s \rangle) = \frac{\textit{count}(\langle s \rangle, \textit{NN})}{\textit{count}(\langle s \rangle)}$

PREDIKSI HMM | TAGGING OTOMATIS

- $\hat{t} = \operatorname{argmax}_t \prod_{i=1}^n P(w_i|t_i)P(t_i|t_{i-1})$
- Jika dilakukan secara greedy: untuk setiap kata cari tag yang memaksimalkan $P(w_i|t_i)P(t_i|t_{i-1})$ dari kiri ke kanan
 - Hasil yang didapatkan tidak akan optimal dan menghasilkan masalah error propagation
 - Nilai yg dicari adalah argmax_t bukan $\operatorname{argmax}_{t_i}$
- Cara yang benar adalah cari semua kombinasi tag yang mungkin, kalkulasi nilainya, lalu ambil yang terbesar
 - Masalahnya adalah jumlah kombinasi tag tersebut terlalu banyak
- Cara yang benar dan lebih efisien adalah algoritma Viterbi

ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

- Memanfaatkan dynamic programming
- Mencatat nilai probabilitas dari setiap tag untuk kata w_i dan melihat bagaimana jika w_i memiliki tag yang berbeda

ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

Probabilitas
Emisi

	Janet	will	back	the	bill
NNP	0.000032	0	0	0.000048	0
MD	0	0.308431	0	0	0
VB	0	0.000028	0.000672	0	0.000028
JJ	0	0	0.000340	0	0
NN	0	0.000200	0.000223	0	0.002337
RB	0	0	0.010446	0	0
DT	0	0	0	0.506099	0

$$P(\text{Janet}|\text{NNP})$$

Probabilitas
Transisi

	NNP	MD	VB	JJ	NN	RB	DT
<s>	0.2767	0.0006	0.0031	0.0453	0.0449	0.0510	0.2026
NNP	0.3777	0.0110	0.0009	0.0084	0.0584	0.0090	0.0025
MD	0.0008	0.0002	0.7968	0.0005	0.0008	0.1698	0.0041
VB	0.0322	0.0005	0.0050	0.0837	0.0615	0.0514	0.2231
JJ	0.0366	0.0004	0.0001	0.0733	0.4509	0.0036	0.0036
NN	0.0096	0.0176	0.0014	0.0086	0.1216	0.0177	0.0068
RB	0.0068	0.0102	0.1011	0.1012	0.0120	0.0728	0.0479
DT	0.1147	0.0021	0.0002	0.2157	0.4744	0.0102	0.0017

$$P(\text{NNP} | <s>)$$

ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

	Janet	will	back	the	bill
NNP					
MD					
VB					
JJ					
NN					
RB					
DT					

ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

	Janet	will	back	the	bill
NP	$P(\text{Janet} \mid \text{NP}) * P(\text{NP} \mid <s>)$				
MD					
VB					
JJ					
NN					
RB					
DT					

ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

	Janet	will	back	the	bill
NNP	0.000032* 0.2767				
MD					
VB					
JJ					
NN					
RB					
DT					

ALGORITMA VITERBI | HMM | TAGGING OTOMATIS


	Janet	will	back	the	bill
NNP	8.8544e-6				
MD	0				
VB	0				
JJ	0				
NN	0				
RB	0				
DT	0				

ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

	Janet	will	back	the	bill
NNP	8.8544e-6	$P(\text{will} \text{NNP}) * P(\text{NNP} t_{\text{Janet}}) * s(t_{\text{Janet}} \text{Janet})$			
MD	0				
VB	0				
JJ	0				
NN	0				
RB	0				
DT	0				

ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

	Janet	will	back	the	bill
NNP	8.8544e-6	$P(\text{will} \text{NNP}) * P(\text{NNP} t_{\text{Janet}}) * s(t_{\text{Janet}} \text{Janet})$	t_{Janet} : semua tag yang mungkin $s()$: skor yang telah dihitung sebelumnya Max($P(\text{will} \text{NNP}) * P(\text{NNP} \text{NNP}) * s(\text{NNP} \text{Janet})$, $P(\text{will} \text{NNP}) * P(\text{NNP} \text{MD}) * s(\text{MD} \text{Janet})$, ... $P(\text{will} \text{NNP}) * P(\text{NNP} \text{DT}) * s(\text{DT} \text{Janet})$)		
MD	0				
VB	0				
JJ	0				
NN	0				
RB	0				
DT	0				



ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

	Janet	will	back	the	bill
NNP	8.8544e-6	0			
MD	0	$P(\text{will} \mid \text{MD}) * P(\text{MD} \mid t_{\text{Janet}}) * s(t_{\text{Janet}} \mid \text{Janet})$	$\begin{aligned} &\text{Max}(P(\text{will} \mid \text{MD}) * P(\text{MD} \mid \text{NNP}) * s(\text{NNP} \mid \text{Janet}), \\ &P(\text{will} \mid \text{MD}) * P(\text{MD} \mid \text{MD}) * s(\text{MD} \mid \text{Janet}), \\ &\dots \\ &P(\text{will} \mid \text{MD}) * P(\text{MD} \mid \text{DT}) * s(\text{DT} \mid \text{Janet})) \end{aligned}$		
VB	0				
JJ	0				
NN	0				
RB	0				
DT	0				


ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

	Janet	will	back	the	bill
NNP	8.8544e-6	0			
MD	0	3.004e-8			
VB	0				
JJ	0				
NN	0				
RB	0				
DT	0				




ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

	Janet	will	back	the	bill
NNP	8.8544e-6	0			
MD	0	3.004e-8			
VB	0	2.231e-13			
JJ	0	0			
NN	0	1.034e-10			
RB	0	0			
DT	0	0			




ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

	Janet	will	back	the	bill
NNP	8.8544e-6	0	0		
MD	0	3.004e-8	0		
VB	0	2.231e-13	$P(\text{back} \mid \text{VB}) * P(\text{VB} \mid t_{\text{will}}) * s(t_{\text{will}} \mid \text{will})$		
JJ	0	0			
NN	0	1.034e-10			
RB	0	0			
DT	0	0			



ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

	Janet	will	back	the	bill
NNP	8.8544e-6	0	0		
MD	0	3.004e-8	0		
VB	0	2.231e-13	MD: 1.6e-11 VB: 7.5e-19 NN: 9.7e-17		
JJ	0	0			
NN	0	1.034e-10			
RB	0	0			
DT	0	0			




ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

	Janet	will	back	the	bill
NNP	8.8544e-6	0	0		
MD	0	3.004e-8	0		
VB	0	2.231e-13	MD: 1.6e-11 VB: 7.5e-19 NN: 9.7e-17		
JJ	0	0			
NN	0	1.034e-10			
RB	0	0			
DT	0	0			



ALGORITMA VITERBI | HMM | TAGGING OTOMATIS


	Janet	will	back	the	bill
NNP	8.8544e-6	0	0		
MD	0	3.004e-8	0		
VB	0	2.231e-13	1.6e-11		
JJ	0	0	5.1e-15		
NN	0	1.034e-10	5.4e-15		
RB	0	0	5.3e-11		
DT	0	0	0		



The diagram illustrates the Viterbi path for the word 'back' (row VB, column back) to the word 'Janet' (row NNP, column Janet). The path is highlighted with blue arrows, showing the sequence of transitions from the word 'back' to the word 'Janet'.

ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

	Janet	will	back	the	bill
NNP	8.8544e-6	0	0	2.5e-17	
MD	0	3.004e-8	0	0	
VB	0	2.231e-13	1.6e-11	0	
JJ	0	0	5.1e-15	5.2e-16	
NN	0	1.034e-10	5.4e-15	5.9e-18	
RB	0	0	5.3e-11	0	
DT	0	0	0	1.8e-12	




The diagram illustrates the Viterbi path for the sentence "Janet will back the bill". The path starts at the word "the" (row VB, column 4) and branches out to the words "Janet", "will", "back", and "bill". The arrows indicate the highest probability path for each word, with the path for "the" being the most likely (2.5e-17).

ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

	Janet	will	back	the	bill
NNP	8.8544e-6	0	0	2.5e-17	0
MD	0	3.004e-8	0	0	0
VB	0	2.231e-13	1.6e-11	0	1.0e-20
JJ	0	0	5.1e-15	5.2e-16	0
NN	0	1.034e-10	5.4e-15	5.9e-18	2.0e-15
RB	0	0	5.3e-11	0	0
DT	0	0	0	1.8e-12	0


ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

	Janet	will	back	the	bill
NNP	8.8544e-6	0	0	2.5e-17	0
MD	0	3.004e-8	0	0	0
VB	0	2.231e-13	1.6e-11	0	1.0e-20
JJ	0	0	5.1e-15	5.2e-16	0
NN	0	1.034e-10	5.4e-15	5.9e-18	2.0e-15
RB	0	0	5.3e-11	0	0
DT	0	0	0	1.8e-12	0



ALGORITMA VITERBI | HMM | TAGGING OTOMATIS


	Janet	will	back	the	bill
NNP	8.8544e-6	0	0	2.5e-17	0
MD	0	3.004e-8	0	0	0
VB	0	2.231e-13	1.6e-11	0	1.0e-20
JJ	0	0	5.1e-15	5.2e-16	0
NN	0	1.034e-10	5.4e-15	5.9e-18	2.0e-15
RB	0	0	5.3e-11	0	0
DT	0	0	0	1.8e-12	0



The diagram illustrates the Viterbi path for the sentence "Janet will back the bill". Blue arrows show the backpointers from the current state to the previous state that maximizes the probability. The path starts at the NN state for "bill" (2.0e-15) and traces back through the VB state for "back" (1.6e-11), the MD state for "will" (3.004e-8), and finally to the NNP state for "Janet" (8.8544e-6). Other arrows show alternative paths that are less probable.


ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

	Janet	will	back	the	bill
NNP	8.8544e-6	0	0	2.5e-17	0
MD	0	3.004e-8	0	0	0
VB	0	2.231e-13	1.6e-11	0	1.0e-20
JJ	0	0	5.1e-15	5.2e-16	0
NN	0	1.034e-10	5.4e-15	5.9e-18	2.0e-15
RB	0	0	5.3e-11	0	0
DT	0	0	0	1.8e-12	0




ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

	Janet	will	back	the	bill
NNP	8.8544e-6	0	0	2.5e-17	0
MD	0	3.004e-8	0	0	0
VB	0	2.231e-13	1.6e-11	0	1.0e-20
JJ	0	0	5.1e-15	5.2e-16	0
NN	0	1.034e-10	5.4e-15	5.9e-18	2.0e-15
RB	0	0	5.3e-11	0	0
DT	0	0	0	1.8e-12	0




ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

	Janet	will	back	the	bill
NNP	8.8544e-6	0	0	2.5e-17	0
MD	0	3.004e-8	0	0	0
VB	0	2.231e-13	1.6e-11	0	1.0e-20
JJ	0	0	5.1e-15	5.2e-16	0
NN	0	1.034e-10	5.4e-15	5.9e-18	2.0e-15
RB	0	0	5.3e-11	0	0
DT	0	0	0	1.8e-12	0




ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

	Janet	will	back	the	bill
NNP	8.8544e-6	0	0	2.5e-17	0
MD	0	3.004e-8	0	0	0
VB	0	2.231e-13	1.6e-11	0	1.0e-20
JJ	0	0	5.1e-15	5.2e-16	0
NN	0	1.034e-10	5.4e-15	5.9e-18	2.0e-15
RB	0	0	5.3e-11	0	0
DT	0	0	0	1.8e-12	0



ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

	Janet / NNP	will / MD	back / VB	the / DT	bill / NN
NNP	8.8544e-6	0	0	2.5e-17	0
MD	0	3.004e-8	0	0	0
VB	0	2.231e-13	1.6e-11	0	1.0e-20
JJ	0	0	5.1e-15	5.2e-16	0
NN	0	1.034e-10	5.4e-15	5.9e-18	2.0e-15
RB	0	0	5.3e-11	0	0
DT	0	0	0	1.8e-12	0



ALGORITMA VITERBI | HMM | TAGGING OTOMATIS

- Memiliki kompleksitas $O(T^2N)$, T adalah jumlah tag sets, dan N adalah panjang sekuens
 - Matriks $T * N$, setiap cell melakukan operasi sebanyak T

HMM | TAGGING OTOMATIS

- Jika sebelumnya menggunakan bigram pada probabilitas transisi, state-of-the-art saat ini menggunakan trigram
 - $P(\mathbf{t}) = \prod_{i=1}^n P(t_i | t_{i-1}, t_{i-2}) \Rightarrow$ kompleksitas Viterbi menjadi $O(T^3N)$
- Perlu menghadapi kemungkinan trigram tidak ada pada data training
 - Menggunakan Interpolation:
 - $P(t_i | t_{i-1}, t_{i-2}) = \lambda_3 P(t_i | t_{i-1}, t_{i-2}) + \lambda_2 P(t_i | t_{i-1}) + \lambda_1 P(t_i)$
 - $\lambda_1 + \lambda_2 + \lambda_3 = 1$
- Akurasi dapat mencapai 96.5% pada dataset Penn Treebank

LATIHAN

	Saya	membaca	buku
NN	0.1	0	0.8
VB	0	0.8	0.1
PRP	0.6	0	0

	NN	VB	PRP
<s>	0.03	0.0004	0.5
NN	0.02	0.2	0.007
VB	0.5	0.002	0.0001
PRP	0.008	0.7	0.00001

Gunakan algoritma Viterbi untuk menentukan tag dari kalimat “Saya membaca buku”



PERTEMUAN BERIKUTNYA ...

Klasifikasi Teks